

Bataille navale

Étude de la confiance accordée à un humain vs une IA

Mallory BARATAY - Patrice KEGLO
Groupe CTRL-Z

Master 1 Génie Logiciel
Faculté des Sciences de Montpellier
Département Informatique

28 mai 2026

- 1 Introduction
- 2 Contexte du Projet
- 3 Développement
- 4 Protocole Expérimental
- 5 Résultats Obtenus
- 6 Conclusion

Introduction

- **Question fondamentale** : Les utilisateurs accordent-ils différemment leur confiance à un adversaire humain vs une IA ?
- **Contexte** : Omniprésence de l'IA dans les interactions quotidiennes
- **Enjeu** : Conception d'interfaces homme-machine éthiques et fiables

Théorie de l'attribution

- Heider (1958), Weiner (1985)
- Explications causales biaisées pour les machines

Étude Ullman et al. (2014)

- Yale University
- Confiance vs tromperie du robot

Anthropomorphisme inversé

- Standards moraux différents selon la cible
- Machines jugées plus sévèrement

Hypothèses de recherche

- H₁** Les participants expriment une évaluation de déloyauté **significativement plus élevée** pour le CheatBot que pour le même comportement attribué à un humain
- H_{2a}** L'ordre de présentation de l'adversaire **influence** les perceptions de triche
- H_{2b}** La confiance **diminue** au fil des tours

Contexte du Projet

Phase 1 : Robot Pepper

- Objectif initial : humain vs humanoïde vs digital
- Intégration avec robot social SoftBank

Problèmes rencontrés

- Parties trop longues (15-30s latence)
- Confonds expérimentaux
- Expérience frustrante

Phase 2 : Pivot vers digital


- Maintien de Python (infrastructure Pepper déjà développée)
- Ajout de couche web (Flask)
- Avantage : contrôle rigoureux, reproductibilité, scalabilité

Développement

Composants clés :

- **Backend Python** : Logique métier, CheatBot, gestion de base de données
- **Frontend Web** : Interface utilisateur (Flask + JavaScript)
- **Communication** : API REST

Plateforme Web : Vue d'ensemble



Routes principales :

- GET / : Landing page
- POST /api/game/new : Créer partie
- POST /api/game/{id}/shoot : Tir joueur
- POST /api/game/{id}/bot-turn : Tour du bot
- POST /api/game/{id}/turn-trust : Enregistrer score
- GET /api/stats : Statistiques globales

 **PEPPER BATTLESHIP**

FONCTIONNALITÉSCOMMENT JOUERRECHERCHE

x Jouer

EXPÉRIENCE DE RECHERCHE · UNIVERSITÉ

POUVEZ-VOUS DÉTECTER LA TRICHE ?

Affrontez notre robot Pepper dans une partie de Bataille Navale. Il maîtrise l'art de tricher discrètement. Saurez-vous le démasquer ?

30
PARTIES JOUÉES


4
TIRS PAR TOUR

10
CONFIGURATIONS

6
BATEAUX EN JEU

x COMMENCER LA PARTIE

Machine d'état



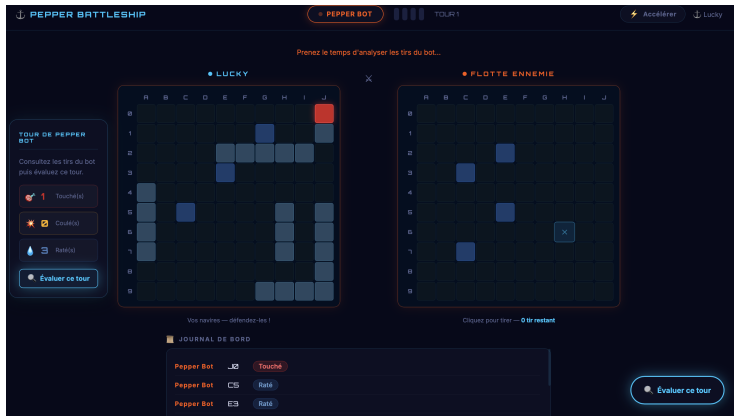
Grilles de jeu

Grille du joueur :

- Ma flotte (6 bateaux)
- Tirs ennemis reçus
- Couleurs

Grille de suivi :


- Mes tirs effectués
- Résultats (touché/raté/coulé)
- Visualisation en temps réel



Système de notation de confiance

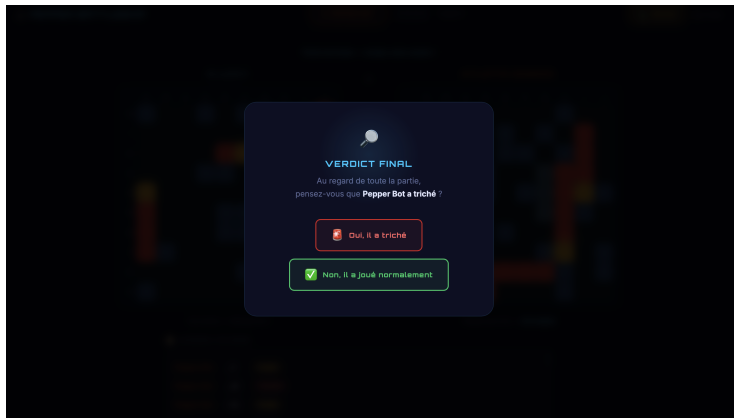
Après chaque tour du bot :

“Le comportement de votre adversaire vous a-t-il semblé suspect ce tour ? ”



A la fin de la partie :

“Au regard de toute la partie, pensez-vous que votre adversaire a triché ?”



Algorithme de triche :

- Accès à la grille ennemie
- Quota prédéfini par tour : [1, 2, 0, 3, 3, 2, 1, 4, 2, 1, 3]

Chaque tour :

- 1 Identification d'un bateau ayant reçu au moins un tir
- 2 Sélection de cases à touché sur ce bateau (succès)
- 3 Sélection des cases vides (échecs)
- 4 Sélection d'un autre bateau pour compléter les tirs si besoin
- 5 Exécution des 4 tirs

Base de données PostgreSQL

Schéma relationnel :

Table Game

- game_id (PK)
- player_name
- player_type
- date_played
- winner

Table Turn

- turn_id (PK)
- game_id (FK)
- turn_number
- bot_quota
- trust_score

Table BotShot

- shot_id (PK)
- turn_id (FK)
- shot_number
- pos_x, pos_y
- result


Game			
SERIAL	id	PK	
TEXT	player_name		
TEXT	player_type		Digital-Web
TIMESTAMP	date_played		DEFAULT CURRENT_TIMESTAMP
TEXT	winner		nom joueur ou bot gagnant
INTEGER	trust_score		score moyen de confiance
INTEGER	trust_final		1 = détecté · 0 = non détecté

BotPersona			
SERIAL	id	PK	
TEXT	name		UNIQUE
TEXT	emoji		DEFAULT 🤖
TEXT	description		
BOOLEAN	active		DEFAULT TRUE

Synchronisation Web ↔ Python

Flux de données complet :

- 1 Utilisateur accède à /game (Flask)
- 2 Flask initialise GameMaster en Python
- 3 Tirs joueur → API /shoot → logique Python
- 4 Tour du bot → appel CheatBot.get_case_played()
- 5 Résultats → enregistrement PostgreSQL
- 6 Scores de confiance → base de données



Protocole Expérimental

Chaque participant joue **2 parties** avec comportement adversaire **identique**

	Partie 1	Partie 2
Condition A	Humain	IA
Condition B	IA	Humain

Phases d'une partie :

- ① Sélection du nom du joueur
- ② Sélection de la configuration de la flotte
- ③ Combat
- ④ Évaluation de confiance après chaque tour du bot
- ⑤ Fin : Victoire ou défaite
- ⑥ Évaluation de perception de triche globale

Variable dépendante principale :

À la fin de chaque tour du bot, le joueur répond :

“Le comportement de votre adversaire vous a-t-il semblé suspect ce tour ? ”

Échelle de Likert 0-5 :

- 0 = Pas du tout triché
- 1-2 = Peu probable
- 3 = Incertain
- 4-5 = Très suspect / Certainement triché

Enregistrement : Horodaté et stocké immédiatement en base

Garantie d'équivalence comportementale :

- **Même adversaire** : Algorithme identique
- **Même quota** : Séquence $[1, 2, \dots, 3]$ répétée

Variable indépendante manipulée :

- Label de l'adversaire
- Ordre de présentation

Variation entre joueurs :

- Chance du joueur à toucher le bot
- **Connaissance du jeu** pour le joueur

Résultats Obtenus


Population :

- Taille de l'échantillon : 28 participants pour 40 parties
- Amis, collègues de l'université et famille
- Diversité d'âge, de genre et de familiarité avec les jeux vidéo
- Majorité masculine (environ 80%)

- H_1 : Différence significative entre les deux labels
- H_{2a} : Effet d'ordre de présentation
- H_{2b} : Diminution de la confiance au fil des tours

Résultats obtenus H_1

Suspicion moyenne par quota






H_1 est confirmée :

- Les utilisateurs appliquent des standards différents selon le label
- Biais systématique dans la perception de tromperie artificielle

Implications pour le design éthique d'IA

Résultats obtenus H_{2a} et H_{2b}



H_{2a} et H_{2b} sont confirmées :

- Léger effet d'ordre
- Augmentation progressive de la suspicion au fil des tours
- Manque de donnée pour confirmer les hypothèses secondaires

Interprétation :

- Biais potentiels à cause de notre proximité avec les joueurs
- Biais systématique dans la perception de tromperie artificielle
- Besoin de transparence et d'explicabilité pour les systèmes d'IA

Conclusion

Apports scientifiques :

- Éclairage sur la confiance homme-machine
- Protocole reproductible

Perspectives futures :

- Augmentation des échantillons pour confirmer l'étude
- Réintégration du robot Pepper
- Étude des facteurs individuels modulant le biais
- Différents contextes compétitifs (poker, jeux de données)

- Architecture web+Python flexible et scalable
- Algorithme de triche contrôlé
- Collecte de données centralisée
- Intégrabilité avec robot physique disponible

Bataille navale

Détection de triche et confiance homme-machine

Faculté des Sciences de Montpellier - Master 1 Génie Logiciel

Questions ?